

UNIVERSIDADE PRESBITERIANA MACKENZIE

Faculdade de Computação e Informática

Tecnologia em Banco de Dados

PROJETO APLICADO I

Etapa 1 — Definição da Organização, do Problema e do Dataset

Estudo de dados aplicado à Olist (marketplace brasileiro de e-commerce)

Aluno: Felipe Passador Leite

RA: 10401969

E-mail: 10401969@mackenzista.com.br

Professor: Fabio Silva Lopes

São Paulo

Setembro de 2026

Sumário

1. Introdução.....	5
2. Membros do Grupo.....	5
3. Contexto do Estudo.....	5
4. Referências de Aquisição do Dataset.....	5
5. Descrição da Origem dos Dados.....	6
6. Descrição do Dataset (Metadados).....	6
7. Cronograma de Atividades.....	9
8. Repositório do Projeto.....	9

Observação: os números de página acima se referem a esta versão do documento (Etapa 1) e serão atualizados conforme o conteúdo for expandido nas etapas seguintes.

Lista de Figuras

Nenhuma figura incluída até o momento. Esta lista será atualizada nas próximas etapas, à medida que gráficos e diagramas forem produzidos na análise exploratória.

Lista de Tabelas

Nenhuma tabela incluída até o momento. Esta lista será atualizada assim que os metadados do dataset (Seção 6) forem detalhados.

1. Introdução

Este documento apresenta a Etapa 1 do Projeto Aplicado I, componente curricular do curso de Tecnologia em Banco de Dados da Universidade Presbiteriana Mackenzie. O objetivo geral do projeto, a ser desenvolvido ao longo do semestre, é realizar um estudo prático de análise de dados sobre uma organização real, culminando em um trabalho de data storytelling que conte, por meio de dados, gráficos e visualizações, uma história relevante sobre essa organização.

Para esta primeira etapa, foi selecionada a organização Olist, marketplace brasileiro de e-commerce, cujos dados públicos e reais estão disponíveis para fins educacionais. Este documento apresenta o contexto do estudo, a organização escolhida, a origem e as características do dataset utilizado, bem como o cronograma de atividades planejado para o desenvolvimento do trabalho.

2. Membros do Grupo

Este trabalho está sendo desenvolvido individualmente, conforme orientação do professor de que grupos podem ter entre uma e quatro pessoas.

Felipe Passador Leite — RA 10401969 — 10401969@mackenzista.com.br

3. Contexto do Estudo

3.1 A organização: Olist

A Olist é descrita, na página oficial do dataset no Kaggle, como uma das maiores plataformas de marketplace do Brasil. A empresa conecta pequenos e médios lojistas de todo o país a diversos canais de venda por meio de um contrato único, cuidando também da logística de entrega em parceria com transportadoras. Dessa forma, pequenos vendedores conseguem distribuir seus produtos em múltiplos marketplaces sem precisar negociar individualmente com cada um deles.

3.2 Problema de pesquisa e objetivo da análise

O problema de pesquisa deste estudo é investigar em que medida atrasos na entrega dos pedidos — comparando a data estimada de entrega (`order_estimated_delivery_date`) com a data real de entrega ao cliente (`order_delivered_customer_date`) — impactam a satisfação do cliente, medida pela nota de avaliação (`review_score`, de 1 a 5).

O objetivo da análise é, a partir do cruzamento das tabelas de pedidos (`olist_orders_dataset`), itens (`olist_order_items_dataset`) e avaliações (`olist_order_reviews_dataset`), identificar padrões entre atraso na entrega e queda na nota de avaliação, além de mapear a frequência desse problema no conjunto de dados — por exemplo, os cerca de 3.000 pedidos que não possuem data de entrega ao cliente registrada, identificados na Seção 6.6 deste documento. Essa investigação será aprofundada na Etapa 2, por meio de técnicas de análise exploratória de dados em Python.

3.3 Associação com os Objetivos de Desenvolvimento Sustentável (ODS)

O problema de pesquisa escolhido relaciona-se principalmente ao ODS 9 — Indústria, Inovação e Infraestrutura, tema diretamente ligado à eficiência da infraestrutura logística e de distribuição de produtos, um dos pilares da operação da Olist como conectora de vendedores a canais de venda. Secundariamente, o tema também toca o ODS 12 — Consumo e Produção Responsáveis, na medida em que atrasos e falhas de entrega representam ineficiências na cadeia de distribuição de produtos.

4. Referências de Aquisição do Dataset

O dataset utilizado neste projeto é o "Brazilian E-Commerce Public Dataset by Olist", disponibilizado publicamente na plataforma Kaggle pelo usuário oficial da empresa (olistbr).

Fonte: <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>

Período da coleta: os dados abrangem aproximadamente 100 mil pedidos realizados na plataforma entre os anos de 2016 e 2018.

Limitações de uso: o dataset é de uso público para fins de estudo e pesquisa (conforme licença disponibilizada no Kaggle). Os dados foram anonimizados pela Olist — por exemplo, na tabela de avaliações, nomes de empresas parceiras mencionados em comentários de texto foram substituídos por nomes de casas fictícias da série Game of Thrones, preservando a confidencialidade comercial dos parceiros.

5. Descrição da Origem dos Dados

Os dados foram gerados a partir da operação real da Olist como marketplace: cada pedido realizado por um cliente em um dos canais de venda parceiros gera registros relacionados a cliente, produto, vendedor, pagamento, frete/entrega e, quando aplicável, avaliação do pedido pelo cliente. Por se tratar de dados operacionais de uma empresa em funcionamento, eles refletem o comportamento real de compra no comércio eletrônico brasileiro entre 2016 e 2018.

6. Descrição do Dataset (Metadados)

O dataset é composto por 9 arquivos no formato CSV, armazenados no repositório do projeto na pasta dados/. Os metadados a seguir foram levantados a partir da leitura direta dos arquivos (contagem real de linhas, colunas e valores), e não de estimativas.

6.1 olist_customers_dataset.csv — 99.441 linhas

Coluna	Descrição
customer_id	Identificador único de cliente por pedido (muda a cada novo pedido do mesmo cliente).
customer_unique_id	Identificador estável do cliente, que se repete caso a mesma pessoa faça mais de um pedido.
customer_zip_code_prefix	Prefixo do CEP do endereço do cliente.
customer_city	Cidade do cliente (4.119 cidades distintas no dataset).
customer_state	Sigla do estado do cliente (27 estados/UFs)

	representados, cobrindo todo o Brasil).
--	---

Observação: não há valores nulos em nenhuma coluna desta tabela. Por conter `customer_id` e `customer_unique_id` distintos, é importante usar `customer_unique_id` (e não `customer_id`) para análises de clientes únicos/recompra.

6.2 olist_geolocation_dataset.csv — 1.000.163 linhas

Coluna	Descrição
<code>geolocation_zip_code_prefix</code>	Prefixo do CEP (19.015 prefixos distintos).
<code>geolocation_lat</code>	Latitude aproximada do CEP.
<code>geolocation_lng</code>	Longitude aproximada do CEP.
<code>geolocation_city</code>	Nome da cidade correspondente ao CEP.
<code>geolocation_state</code>	Sigla do estado correspondente ao CEP.

Observação: é a maior tabela do dataset (61,3 MB). Não há valores nulos. Pode haver múltiplas linhas para o mesmo prefixo de CEP (várias coordenadas por prefixo).

6.3 olist_order_items_dataset.csv — 112.650 linhas

Coluna	Descrição
<code>order_id</code>	Identificador do pedido ao qual o item pertence.
<code>order_item_id</code>	Número sequencial do item dentro do pedido (um pedido pode ter mais de um item).
<code>product_id</code>	Identificador do produto vendido.
<code>seller_id</code>	Identificador do vendedor responsável pelo item.
<code>shipping_limit_date</code>	Data-limite para o vendedor entregar o item à transportadora.
<code>price</code>	Preço do item (em reais).
<code>freight_value</code>	Valor do frete referente ao item.

Observação: não há valores nulos. Esta tabela liga pedidos, produtos e vendedores, e é central para análises de preço e frete.

6.4 olist_order_payments_dataset.csv — 103.886 linhas

Coluna	Descrição
<code>order_id</code>	Identificador do pedido.
<code>payment_sequential</code>	Número sequencial do pagamento (um pedido pode ter mais de uma forma/parcela de pagamento).
<code>payment_type</code>	Tipo de pagamento. Valores observados: boleto, credit_card, debit_card, voucher, not_defined.
<code>payment_installments</code>	Número de parcelas (variando de 0 a 24 no dataset).
<code>payment_value</code>	Valor pago (em reais).

Observação: não há valores nulos. O número de parcelas elevado (até 24x) é uma característica conhecida do comércio brasileiro, onde o parcelamento funciona como uma forma de crédito ao consumidor.

6.5 olist_order_reviews_dataset.csv — 99.224 linhas

Coluna	Descrição
<code>review_id</code>	Identificador da avaliação.
<code>order_id</code>	Identificador do pedido avaliado.
<code>review_score</code>	Nota da avaliação, de 1 a 5.
<code>review_comment_title</code>	Título do comentário (texto livre; 87.656 valores nulos — a maioria das avaliações não tem título).
<code>review_comment_message</code>	Mensagem do comentário (texto livre; 58.247 valores nulos — muitas avaliações têm apenas a nota, sem texto).

review_creation_date	Data em que a avaliação foi enviada pelo cliente.
review_answer_timestamp	Data/hora em que a avaliação foi respondida na plataforma.

Observação: esta é a tabela mencionada no material de apoio da disciplina como tendo passado por anonimização — nomes de empresas eventualmente citados nos comentários foram substituídos por nomes de casas da série Game of Thrones.

6.6 olist_orders_dataset.csv — 99.441 linhas

Coluna	Descrição
order_id	Identificador único do pedido.
customer_id	Identificador do cliente (por pedido) que fez a compra.
order_status	Situação do pedido. Valores observados: delivered, shipped, canceled, unavailable, invoiced, processing, created, approved.
order_purchase_timestamp	Data/hora da compra.
order_approved_at	Data/hora da aprovação do pagamento (160 valores nulos).
order_delivered_carrier_date	Data em que o pedido foi entregue à transportadora (1.783 valores nulos).
order_delivered_customer_date	Data em que o pedido chegou ao cliente (2.965 valores nulos — provavelmente pedidos não entregues ou ainda em trânsito).
order_estimated_delivery_date	Data estimada de entrega informada ao cliente no momento da compra.

Observação: esta tabela é central para o projeto, pois permite calcular prazos de entrega (real vs. estimado) e é a que mais se conecta às demais tabelas (clientes, itens, pagamentos e avaliações).

6.7 olist_products_dataset.csv — 32.951 linhas

Coluna	Descrição
product_id	Identificador único do produto.
product_category_name	Categoria do produto, em português (610 valores nulos; 73 categorias distintas no total).
product_name_lenght	Quantidade de caracteres do nome do produto (610 valores nulos).
product_description_lenght	Quantidade de caracteres da descrição do produto (610 valores nulos).
product_photos_qty	Quantidade de fotos do produto no anúncio (610 valores nulos).
product_weight_g	Peso do produto em gramas (2 valores nulos).
product_length_cm	Comprimento do produto em centímetros (2 valores nulos).
product_height_cm	Altura do produto em centímetros (2 valores nulos).
product_width_cm	Largura do produto em centímetros (2 valores nulos).

Observação: os nomes das colunas de dimensão de texto mantêm a grafia original do dataset ("lenght", sem o 'g'), que é um erro de digitação do arquivo original e não deve ser corrigido ao carregar os dados, sob risco de quebrar a leitura.

6.8 olist_sellers_dataset.csv — 3.095 linhas

Coluna	Descrição
seller_id	Identificador único do vendedor.
seller_zip_code_prefix	Prefixo do CEP do vendedor.

seller_city	Cidade do vendedor.
seller_state	Sigla do estado do vendedor (23 estados representados).

Observação: não há valores nulos.

6.9 product_category_name_translation.csv — 71 linhas

Coluna	Descrição
product_category_name	Nome da categoria em português, como aparece em olist_products_dataset.csv.
product_category_name_english	Tradução do nome da categoria para o inglês.

Observação: tabela pequena, de apoio, usada apenas para traduzir os nomes de categoria da tabela de produtos.

7. Cronograma de Atividades

O cronograma abaixo é uma estimativa construída com base na estrutura de aproximadamente 30 dias por etapa apresentada nos slides da disciplina ("Orientações Iniciais"). As datas exatas de entrega de cada etapa devem ser confirmadas no AVA assim que forem publicadas pelo professor; este cronograma será revisado conforme necessário.

Etapa	Período	Atividades principais
Etapa 1	Até 14/09/2026	Escolha da organização (Olist); criação e organização do repositório GitHub; obtenção do dataset; documentação dos metadados; definição do problema de pesquisa e do(s) ODS; elaboração deste documento.
Etapa 2 (estimado)	~15/09 a ~14/10/2026	Análise exploratória de dados em Python/Jupyter Notebook: tratamento e limpeza dos dados, cálculo dos atrasos de entrega, cruzamento com as notas de avaliação, geração de gráficos e primeiras interpretações.
Etapa 3 (estimado)	~15/10 a ~14/11/2026	Estruturação da apresentação de resultados analíticos e construção do data storytelling.
Etapa 4 (estimado)	~15/11 a ~14/12/2026	Ajustes finais no relatório, gravação do vídeo de síntese do estudo e entrega final do projeto.

8. Repositório do Projeto

Todos os artefatos do projeto (documentação e dataset) estão disponíveis publicamente em:

<https://github.com/fpassr/Projeto-Aplicado-I>