

UNIVERSIDADE PRESBITERIANA MACKENZIE

Faculdade de Computação e Informática

Tecnologia em Banco de Dados

PROJETO APLICADO I

Etapa 2 — Proposta de Solução Analítica e Análise Exploratória de Dados

Estudo de dados aplicado à Olist (marketplace brasileiro de e-commerce)

Aluno: Felipe Passador Leite

RA: 10401969

E-mail: 10401969@mackenzista.com.br

Professor: Fabio Silva Lopes

São Paulo

Outubro de 2026

Sumário

1. Introdução
2. Membros do Grupo
3. Glossário
4. Lista de Abreviaturas e Siglas
5. Objetivo de Estudo
6. Contexto do Estudo
7. Referências de Aquisição do Dataset
8. Descrição da Origem dos Dados
9. Descrição do Dataset (Metadados)
10. Proposta de Solução Analítica
11. Análise Exploratória de Dados
12. Cronograma de Atividades
13. Repositório do Projeto

Observação: esta versão (Etapa 2) não traz números de página fixos no sumário, pois o documento ainda crescerá nas Etapas 3 e 4; eles serão adicionados na entrega final.

Lista de Figuras

Figura 1 — Distribuição do atraso de entrega e frequência das notas de avaliação

Figura 2 — Boxplot do atraso de entrega (identificação de outliers)

Figura 3 — Atraso médio de entrega por nota de avaliação

Figura 4 — Matriz de correlação entre variáveis numéricas

Lista de Tabelas

Tabela 1 a 9 — Descrição dos atributos (metadados) de cada arquivo do dataset (Seção 9)

Tabela 10 — Metadados padronizados do dataset (Seção 9.10)

Tabela 11 — Cronograma de atividades (Seção 12)

1. Introdução

Este documento apresenta a Etapa 2 do Projeto Aplicado I, componente curricular do curso de Tecnologia em Banco de Dados da Universidade Presbiteriana Mackenzie, dando continuidade ao trabalho iniciado na Etapa 1. Nesta etapa, o documento evolui para o formato de Proposta de Solução Analítica, incorporando glossário, lista de abreviaturas, objetivo de estudo em frase única, e a Análise Exploratória de Dados (AED) realizada em Python sobre o dataset da organização escolhida.

A organização estudada continua sendo a Olist, marketplace brasileiro de e-commerce, e o problema de pesquisa — investigar a relação entre atrasos na entrega e a satisfação do cliente — foi aprofundado nesta etapa com dados reais, por meio de um notebook Jupyter disponível no repositório do projeto.

2. Membros do Grupo

Este trabalho está sendo desenvolvido individualmente, conforme orientação do professor de que grupos podem ter entre uma e quatro pessoas.

Felipe Passador Leite — RA 10401969 — 10401969@mackenzista.com.br

3. Glossário

Lista de termos específicos do contexto deste estudo (e-commerce e ciência de dados), para facilitar a compreensão do documento por um leitor não familiarizado com a área.

Termo	Definição
Marketplace	Plataforma digital que reúne diversos vendedores (lojistas) em um único canal de vendas, intermediando a venda entre o lojista e o consumidor final.
Dataset	Conjunto de dados estruturado, geralmente organizado em tabelas, usado como base para uma análise.
Metadados	Dados que descrevem outros dados — por exemplo, o significado, o tipo e a origem de cada coluna de uma tabela.
Outlier	Valor atípico, muito distante dos demais valores de uma variável, que pode indicar uma situação excepcional ou um erro de coleta.
Review score	Nota de avaliação dada pelo cliente a um pedido, em uma escala de 1 (muito insatisfeito) a 5 (muito satisfeito).
Frete (freight)	Valor cobrado pelo transporte do produto até o cliente.
Correlação	Medida estatística que indica o grau de relação entre duas variáveis numéricas, variando de -1 (relação inversa perfeita) a +1 (relação direta perfeita).
Data storytelling	Técnica de comunicação que utiliza dados, gráficos e narrativa para contar uma história e transmitir uma mensagem de forma clara.

4. Lista de Abreviaturas e Siglas

Sigla	Significado
AED	Análise Exploratória de Dados
AVA	Ambiente Virtual de Aprendizagem
CD	Ciência de Dados
CSV	Comma-Separated Values (formato de arquivo de dados separados por vírgula)
IQR	Interquartile Range (intervalo interquartil, usado para identificar outliers)
LGPD	Lei Geral de Proteção de Dados (Lei nº 13.709/2018)
ODS	Objetivos de Desenvolvimento Sustentável (ONU)
RA	Registro Acadêmico

5. Objetivo de Estudo

Investigar, por meio de análise exploratória de dados reais da Olist, em que medida o atraso e a duração da entrega dos pedidos se relacionam com a satisfação do cliente, medida pela nota de avaliação, de modo a propor uma solução analítica que apoie a redução desse impacto.

6. Contexto do Estudo

6.1 A organização: Olist

A Olist é descrita, na página oficial do dataset no Kaggle, como uma das maiores plataformas de marketplace do Brasil. A empresa conecta pequenos e médios lojistas de todo o país a diversos canais de venda por meio de um contrato único, cuidando também da logística de entrega em parceria com transportadoras. Dessa forma, pequenos vendedores conseguem distribuir seus produtos em múltiplos marketplaces sem precisar negociar individualmente com cada um deles.

Dados complementares sobre a empresa, levantados em reportagens especializadas (TechCrunch) e na base de dados CBInsights, referentes principalmente ao período de 2021 (ano da rodada de investimento Série E):

Fundação e sede	Fundada em 2015 (originalmente com o nome Solidarium), com sede em Curitiba (PR).
Fundador/CEO	Tiago Dalvi.
Porte (colaboradores)	Cerca de 500 colaboradores em dezembro de 2020, crescendo para aproximadamente 1.400 em dezembro de 2021 (a empresa relata ter triplicado de tamanho em 2021).
Base de clientes (lojistas)	Mais de 45.000 lojistas/varejistas clientes, segundo declaração do próprio CEO à imprensa em dezembro de 2021.
Escopo de atuação	Além do marketplace (Olist Store), a empresa passou a oferecer sistema de ERP, conta digital para gestão financeira, sistema de PDV (ponto de venda) integrado e ferramentas para criação de vitrines virtuais (Olist Shops).
Expansões recentes (2021)	Quatro aquisições no ano: Clickspace (social commerce), PAX Logística (mais de 4.000 motoristas cadastrados), VNDA e Tiny ERP

	(ferramentas de comércio para pequenos negócios).
Captação de investimento	Mais de US\$ 318 milhões captados desde a fundação, atingindo valuation de US\$ 1,5 bilhão na rodada Série E (dezembro de 2021), liderada pela Wellington Management, com participação de Goldman Sachs Asset Management e SoftBank, entre outros.
Concorrentes	Segundo a base CBInsights, concorrentes diretos incluem Nuvemshop, VTEX, Elo7, Linx e Cnova.

Observação: estes dados têm como referência principalmente o ano de 2021 (mais recentes disponíveis nas fontes consultadas) e podem não refletir o porte ou o escopo atual da empresa. Uma declaração oficial de missão, visão e valores, nas palavras da própria Olist, não foi localizada nas fontes consultadas até o momento.

6.2 Problema de pesquisa

O problema de pesquisa deste estudo é investigar em que medida atrasos na entrega dos pedidos — comparando a data estimada de entrega (`order_estimated_delivery_date`) com a data real de entrega ao cliente (`order_delivered_customer_date`) — impactam a satisfação do cliente, medida pela nota de avaliação (`review_score`, de 1 a 5).

Na Etapa 2, este problema foi investigado com dados reais, cujos resultados estão detalhados na Seção 11 (Análise Exploratória de Dados) deste documento.

6.3 Associação com os Objetivos de Desenvolvimento Sustentável (ODS)

O problema de pesquisa escolhido relaciona-se principalmente ao ODS 9 — Indústria, Inovação e Infraestrutura, tema diretamente ligado à eficiência da infraestrutura logística e de distribuição de produtos, um dos pilares da operação da Olist como conectora de vendedores a canais de venda. Secundariamente, o tema também toca o ODS 12 — Consumo e Produção Responsáveis, na medida em que atrasos e falhas de entrega representam ineficiências na cadeia de distribuição de produtos.

7. Referências de Aquisição do Dataset

O dataset utilizado neste projeto é o "Brazilian E-Commerce Public Dataset by Olist", disponibilizado publicamente na plataforma Kaggle pelo usuário oficial da empresa (olistbr).

Fonte: <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>

Período da coleta: os dados abrangem aproximadamente 100 mil pedidos realizados na plataforma entre os anos de 2016 e 2018.

Limitações de uso: o dataset é de uso público para fins de estudo e pesquisa (conforme licença disponibilizada no Kaggle). Os dados foram anonimizados pela Olist — por exemplo, na tabela de avaliações, nomes de empresas parceiras mencionados em comentários de texto foram substituídos por nomes de casas fictícias da série Game of Thrones, preservando a confidencialidade comercial dos parceiros.

8. Descrição da Origem dos Dados

Os dados foram gerados a partir da operação real da Olist como marketplace: cada pedido realizado por um cliente em um dos canais de venda parceiros gera registros relacionados a cliente, produto, vendedor, pagamento, frete/entrega e, quando aplicável, avaliação do pedido pelo cliente. Por se tratar de dados operacionais de uma empresa em funcionamento, eles refletem o comportamento real de compra no comércio eletrônico brasileiro entre 2016 e 2018.

9. Descrição do Dataset (Metadados)

O dataset é composto por 9 arquivos no formato CSV, armazenados no repositório do projeto na pasta dados/. Os metadados a seguir foram levantados a partir da leitura direta dos arquivos (contagem real de linhas, colunas e valores), e não de estimativas.

9.1 olist_customers_dataset.csv — 99.441 linhas

Coluna	Descrição
customer_id	Identificador único de cliente por pedido (muda a cada novo pedido do mesmo cliente).
customer_unique_id	Identificador estável do cliente, que se repete caso a mesma pessoa faça mais de um pedido.
customer_zip_code_prefix	Prefixo do CEP do endereço do cliente.
customer_city	Cidade do cliente (4.119 cidades distintas no dataset).
customer_state	Sigla do estado do cliente (27 estados/UFs representados, cobrindo todo o Brasil).

Observação: não há valores nulos em nenhuma coluna desta tabela.

9.2 olist_geolocation_dataset.csv — 1.000.163 linhas

Coluna	Descrição
geolocation_zip_code_prefix	Prefixo do CEP (19.015 prefixos distintos).
geolocation_lat	Latitude aproximada do CEP.
geolocation_lng	Longitude aproximada do CEP.
geolocation_city	Nome da cidade correspondente ao CEP.
geolocation_state	Sigla do estado correspondente ao CEP.

Observação: é a maior tabela do dataset (61,3 MB). Não há valores nulos.

9.3 olist_order_items_dataset.csv — 112.650 linhas

Coluna	Descrição
order_id	Identificador do pedido ao qual o item pertence.
order_item_id	Número sequencial do item dentro do pedido.
product_id	Identificador do produto vendido.
seller_id	Identificador do vendedor responsável pelo item.
shipping_limit_date	Data-limite para o vendedor entregar o item à transportadora.
price	Preço do item (em reais).
freight_value	Valor do frete referente ao item.

Observação: não há valores nulos.

9.4 olist_order_payments_dataset.csv — 103.886 linhas

Coluna	Descrição
order_id	Identificador do pedido.
payment_sequential	Número sequencial do pagamento.
payment_type	Tipo de pagamento. Valores observados: boleto, credit_card, debit_card, voucher, not_defined.
payment_installments	Número de parcelas (de 0 a 24 no dataset).
payment_value	Valor pago (em reais).

Observação: não há valores nulos.

9.5 olist_order_reviews_dataset.csv — 99.224 linhas

Coluna	Descrição
review_id	Identificador da avaliação.
order_id	Identificador do pedido avaliado.
review_score	Nota da avaliação, de 1 a 5.
review_comment_title	Título do comentário (87.656 valores nulos).
review_comment_message	Mensagem do comentário (58.247 valores nulos).
review_creation_date	Data em que a avaliação foi enviada.
review_answer_timestamp	Data/hora em que a avaliação foi respondida na plataforma.

9.6 olist_orders_dataset.csv — 99.441 linhas

Coluna	Descrição
order_id	Identificador único do pedido.
customer_id	Identificador do cliente (por pedido).
order_status	Situação do pedido (delivered, shipped, canceled, unavailable, invoiced, processing, created, approved).
order_purchase_timestamp	Data/hora da compra.
order_approved_at	Data/hora da aprovação do pagamento (160 valores nulos).
order_delivered_carrier_date	Data de entrega à transportadora (1.783 valores nulos).
order_delivered_customer_date	Data de entrega ao cliente (2.965 valores nulos).
order_estimated_delivery_date	Data estimada de entrega informada ao cliente.

9.7 olist_products_dataset.csv — 32.951 linhas

Coluna	Descrição
product_id	Identificador único do produto.
product_category_name	Categoria do produto, em português (610 valores nulos; 73 categorias distintas).
product_name_lenght	Quantidade de caracteres do nome do produto (610 valores nulos).
product_description_lenght	Quantidade de caracteres da descrição (610 valores nulos).
product_photos_qty	Quantidade de fotos do anúncio (610 valores nulos).
product_weight_g	Peso em gramas (2 valores nulos).
product_length_cm, height_cm, width_cm	Dimensões do produto em centímetros (2 valores nulos cada).

9.8 olist_sellers_dataset.csv — 3.095 linhas

Coluna	Descrição
--------	-----------

seller_id	Identificador único do vendedor.
seller_zip_code_prefix	Prefixo do CEP do vendedor.
seller_city	Cidade do vendedor.
seller_state	Sigla do estado do vendedor (23 estados representados).

9.9 product_category_name_translation.csv — 71 linhas

Coluna	Descrição
product_category_name	Nome da categoria em português.
product_category_name_english	Tradução da categoria para o inglês.

9.10 Metadados padronizados do dataset (visão geral)

Conforme o padrão apresentado na Aula 2 da disciplina, seguem os metadados gerais do dataset como um todo.

Tipo de arquivo	CSV (Comma-Separated Values), 9 arquivos.
Origem dos dados	Aberta (dataset público no Kaggle, publicado pela própria Olist).
Sensibilidade	Dados anonimizados pela Olist. Não há nomes de pessoas físicas; há localização aproximada (cidade/estado e CEP agregado por prefixo) de clientes e vendedores, o que exige cuidado ao divulgar granularidades mais finas.
Validade	Dados coletados entre 2016 e 2018. Refletem o comportamento do e-commerce brasileiro nesse período; podem não representar o cenário atual (ex.: prazos de entrega, meios de pagamento e comportamento do consumidor evoluem ao longo do tempo).
Proprietário do dado	Olist (empresa), que disponibilizou o dataset publicamente na plataforma Kaggle.
Informações adicionais	O dataset é amplamente utilizado em projetos educacionais de ciência de dados, com mais de 800 notebooks públicos de outros autores disponíveis na própria página do Kaggle.
Restrições de uso (LGPD)	Por se tratar de dados já anonimizados e disponibilizados publicamente pela própria empresa responsável, para fins educacionais, não foram identificadas restrições adicionais de uso à luz da LGPD. Ainda assim, nenhuma tentativa de reidentificação de clientes ou vendedores deve ser realizada.
Descrição dos atributos	Detalhada por arquivo nas Seções 9.1 a 9.9 deste documento.

10. Proposta de Solução Analítica

Com base na análise exploratória detalhada na Seção 11, propõe-se o desenvolvimento de um painel analítico (a ser detalhado nas Etapas 3 e 4) que relacione o desempenho de entrega (atraso e tempo total) com a satisfação do cliente, por categoria de produto e por região (estado) do cliente. O objetivo prático dessa proposta é apoiar a Olist na identificação de rotas, regiões ou categorias de produto com maior risco de atraso, de modo a priorizar ações corretivas junto a vendedores e transportadoras parceiras.

Esta proposta parte de uma leitura inicial dos dados e do contexto da empresa: o que mais chama atenção é que, mesmo a maioria dos pedidos sendo entregue antes do prazo estimado (ver Seção 11), ainda existe uma parcela relevante de pedidos com atrasos muito acima da média (outliers de até 188 dias), e essa parcela parece estar diretamente associada a notas de avaliação mais baixas. O "gap" identificado é que a Olist aparentemente já estima prazos de entrega com folga (em média, a entrega real acontece quase 12 dias antes do prazo estimado), mas não há evidência, nos dados disponíveis, de um mecanismo que trate de forma diferenciada os pedidos com alto risco de atraso.

10.1 Pipeline de dados para apoiar o processo analítico

O termo "pipeline de dados" não foi detalhado nos materiais de apoio da disciplina disponibilizados até o momento; a descrição abaixo segue o conceito geral da área de Ciência de Dados, descrevendo as etapas efetivamente realizadas (ou planejadas) neste projeto com os dados da Olist.

1. Extração	Download dos 9 arquivos CSV públicos do Kaggle (olistbr/brazilian-ecommerce) e armazenamento no repositório GitHub do projeto (pasta dados/).
2. Carga	Leitura dos arquivos CSV com a biblioteca pandas, em um notebook Jupyter (Python).
3. Tratamento/Limpeza	Conversão de colunas de data (texto) para o tipo datetime; cálculo de variáveis derivadas (atraso_entrega_dias, tempo_entrega_dias); identificação e contagem de valores nulos.
4. Análise exploratória	Cálculo de medidas de posição e dispersão, análise de distribuição e frequência, identificação de outliers (método IQR) e cálculo de correlações entre variáveis (Seção 11).
5. Visualização	Geração de gráficos (histogramas, boxplot, gráfico de barras e matriz de correlação) com as bibliotecas matplotlib e seaborn.
6. Próximos passos (Etapas 3 e 4)	Estruturação dos achados em um formato de data storytelling e, eventualmente, construção de um painel (dashboard) analítico de apoio à tomada de decisão.

11. Análise Exploratória de Dados

Esta seção descreve, em texto, os principais resultados obtidos no notebook Jupyter "01_analise_exploratoria_olist.ipynb", disponível no repositório do projeto (pasta notebooks/), complementando os metadados apresentados na Seção 9.

11.1 Dimensões e tipos de dados

O dataset completo soma 9 tabelas, com destaque para a tabela orders (99.441 linhas, 8 colunas originais) e order_reviews (99.224 linhas, 7 colunas). As colunas de data da tabela orders estavam originalmente como texto e foram convertidas para o tipo datetime antes da análise.

11.2 Valores ausentes (missing values)

Na tabela orders, 2.965 pedidos (2,98% do total) não possuem data de entrega ao cliente registrada; desses, a maioria está com status "shipped" (1.107), "canceled" (619) ou

"unavailable" (609), ou seja, pedidos que não chegaram a ser efetivamente entregues. Na tabela `order_reviews`, 87.656 avaliações não têm título de comentário e 58.247 não têm mensagem de texto — a maior parte dos clientes avalia apenas com a nota, sem escrever comentário.

11.3 Medidas de posição e dispersão

Para a variável `atraso_entrega_dias` (diferença entre a data real e a data estimada de entrega, calculada sobre 96.476 pedidos com data registrada): média de -11,88 dias, mediana de -12 dias, moda de -14 dias, variando de -147 (muito adiantado) a +188 dias (muito atrasado). O desvio padrão é de 10,18 dias, com coeficiente de variação de -85,75%, indicando grande dispersão relativa.

Para a variável `tempo_entrega_dias` (tempo entre compra e entrega): média de 12,09 dias, mediana de 10 dias, moda de 7 dias, desvio padrão de 9,55 dias.

Para `review_score`: média de 4,09, mediana e moda iguais a 5 (a nota mais comum é a máxima), desvio padrão de 1,35.

11.4 Distribuição e frequência




Figura 1 — Distribuição do atraso de entrega e frequência das notas de avaliação

A distribuição do atraso de entrega é concentrada à esquerda do zero (entregas antecipadas), com uma cauda à direita representando os pedidos atrasados. Já a distribuição das notas de avaliação é fortemente concentrada na nota 5 (57.328 avaliações), seguida da nota 4, com uma quantidade menor, mas não desprezível, de notas 1 (11.424 avaliações).

Quanto ao status dos pedidos (`order_status`), 97,02% estão com status "delivered" (entregue), e os demais 2,98% distribuídos entre shipped, canceled, unavailable, invoiced, processing, created e approved.

11.5 Outliers




Figura 2 — Boxplot do atraso de entrega (identificação de outliers)

Pelo método do intervalo interquartil (IQR), foram identificados 4.301 pedidos (4,46% dos pedidos com data de entrega) como outliers de atraso, ou seja, com atraso muito acima ou abaixo do padrão da maioria dos pedidos. O limite superior calculado pelo método foi de 8 dias de atraso; o pedido mais extremo chegou a 188 dias de atraso.

11.6 Correlações



Figura 3 — Atraso médio de entrega (dias) por nota de avaliação

A correlação entre atraso de entrega e nota de avaliação é de -0,267 — negativa, como esperado pela hipótese do problema de pesquisa: quanto maior o atraso, menor tende a ser a nota. Essa relação fica ainda mais clara ao observar o atraso médio por nota: pedidos avaliados com nota 1 têm, em média, apenas 4,06 dias de antecipação na entrega, enquanto pedidos avaliados com nota 5 têm, em média, 13,39 dias de antecipação — ou seja, entregas mais rápidas em relação ao prazo estimado associam-se a notas melhores.




Figura 4 — Matriz de correlação entre variáveis numéricas

A matriz de correlação revela um achado adicional relevante: o tempo total de entrega (tempo_entrega_dias) tem correlação ainda mais forte com a nota de avaliação (-0,33) do que o atraso em si (-0,27). Isso sugere que a percepção do cliente é influenciada tanto pelo cumprimento do prazo quanto pela duração absoluta da espera. As variáveis de preço e frete apresentaram correlação fraca com a nota de avaliação (-0,04 e -0,09, respectivamente), indicando que, neste dataset, o fator logístico (tempo/atraso) parece pesar mais na satisfação do cliente do que o valor pago pelo produto ou pelo frete.

11.7 Síntese dos achados

Os resultados da análise exploratória confirmam, com dados reais, a relação hipotetizada no problema de pesquisa: atrasos e tempos de entrega mais longos estão associados a notas de avaliação mais baixas. Esses achados embasam a proposta de solução analítica apresentada na Seção 10, voltada à identificação antecipada de pedidos com maior risco de atraso.

12. Cronograma de Atividades

O cronograma abaixo foi atualizado em relação à Etapa 1, refletindo a conclusão da Etapa 2 e mantendo a estimativa de aproximadamente 30 dias por etapa para as etapas seguintes, a confirmar no AVA.

Etapa	Período	Atividades principais
Etapa 1	Concluída (até 14/09/2026)	Escolha da organização (Olist); criação do repositório GitHub; obtenção do dataset; metadados iniciais; definição do problema de pesquisa e do(s) ODS.
Etapa 2	Concluída (até 02/10/2026)	Análise exploratória de dados em Python/Jupyter Notebook; glossário e lista de abreviaturas; metadados padronizados; proposta de solução analítica e pipeline de dados.
Etapa 3 (estimado)	~03/10 a ~02/11/2026	Estruturação da apresentação de resultados analíticos e construção

		do data storytelling.
Etapa 4 (estimado)	~03/11 a ~02/12/2026	Ajustes finais no relatório, gravação do vídeo de síntese do estudo e entrega final do projeto.

13. Repositório do Projeto

Todos os artefatos do projeto (documentação, dataset e notebooks) estão disponíveis publicamente em:

<https://github.com/fpassr/Projeto-Aplicado-I>