UNIVERSIDADE PRESBITERIANA MACKENZIE

Faculdade de Computação e Informática

Tecnologia em Banco de Dados

PROJETO APLICADO I

Olist: o Peso da Espera

Etapa 3 — Análise Exploratória de Dados e Esboço do Data Storytelling

Estudo de dados aplicado à Olist (marketplace brasileiro de e-commerce)

Aluno: Felipe Passador Leite

RA: 10401969

E-mail: 10401969@mackenzista.com.br

Professor: Fabio Silva Lopes

São Paulo

Novembro de 2026

Sumário

1. Introdução
2. Membros do Grupo
3. Glossário
4. Lista de Abreviaturas e Siglas
5. Objetivo de Estudo
6. Contexto do Estudo
7. Referências de Aquisição do Dataset
8. Descrição da Origem dos Dados
9. Descrição do Dataset (Metadados)
10. Proposta de Solução Analítica
11. Análise Exploratória de Dados
12. Esboço do Data Storytelling
13. Cronograma de Atividades
14. Repositório do Projeto
15. Referências

Lista de Figuras

Figura 1 — Distribuição do atraso de entrega e frequência das notas de avaliação
Figura 2 — Distribuição das demais variáveis numéricas (até o percentil 99)
Figura 3 — Boxplot do atraso de entrega (identificação de outliers)
Figura 4 — Atraso médio de entrega (dias) por nota de avaliação
Figura 5 — Matriz de correlação entre variáveis numéricas
Figura 6 — Percentual de avaliações com nota 1 ou 2: no prazo × atrasado
Figura 7 — Nota média de avaliação por faixa de atraso
Figura 8 — Percentual de pedidos entregues com atraso, por estado do cliente (≥ 500 pedidos)

Lista de Tabelas

Tabela 1 — Glossário
Tabela 2 — Abreviaturas e siglas
Tabela 3 — Dados complementares sobre a Olist
Tabela 4 — Atributos de olist_customers_dataset.csv
Tabela 5 — Atributos de olist_geolocation_dataset.csv
Tabela 6 — Atributos de olist_order_items_dataset.csv
Tabela 7 — Atributos de olist_order_payments_dataset.csv
Tabela 8 — Atributos de olist_order_reviews_dataset.csv
Tabela 9 — Atributos de olist_orders_dataset.csv
Tabela 10 — Atributos de olist_products_dataset.csv
Tabela 11 — Atributos de olist_sellers_dataset.csv
Tabela 12 — Atributos de product_category_name_translation.csv
Tabela 13 — Metadados padronizados do dataset
Tabela 14 — Pipeline de dados do projeto
Tabela 15 — Perfil das colunas numéricas (inclui as duas variáveis derivadas)
Tabela 16 — Perfil das colunas categóricas, identificadores e datas em texto
Tabela 17 — Perfil das colunas de data da tabela orders (após conversão para datetime)
Tabela 18 — Medidas de posição e dispersão das variáveis do problema de pesquisa
Tabela 19 — Nota média e notas baixas por faixa de atraso
Tabela 20 — Elementos do esboço do storytelling
Tabela 21 — Roteiro do vídeo de apresentação
Tabela 22 — Cronograma de atividades

1. Introdução

Este documento apresenta a Etapa 3 do Projeto Aplicado I, componente curricular do curso de Tecnologia em Banco de Dados da Universidade Presbiteriana Mackenzie. Ele dá continuidade ao documento construído nas Etapas 1 e 2 e incorpora dois elementos novos, solicitados para esta etapa: a ampliação da Seção de Análise Exploratória de Dados (AED), agora com a descrição estatística de todas as colunas do dataset, e o **Esboço do Data Storytelling**, que descreve a narrativa que será utilizada na gravação do vídeo final de apresentação dos resultados.

A organização estudada continua sendo a Olist, marketplace brasileiro de e-commerce, e o problema de pesquisa permanece o mesmo: investigar a relação entre os atrasos na entrega dos pedidos e a satisfação do cliente. O projeto recebeu, nesta etapa, o nome **“Olist: o Peso da Espera”**, que resume o principal achado da análise — a espera do cliente, e não o preço pago, é o fator que mais pesa na avaliação do pedido.

Os scripts da análise exploratória foram revisados e ampliados no notebook Jupyter “01_analise_exploratoria_olist.ipynb”, disponível na pasta notebooks/ do repositório público do projeto.

2. Membros do Grupo

Este trabalho está sendo desenvolvido individualmente, conforme orientação do professor de que grupos podem ter entre uma e quatro pessoas.

- Felipe Passador Leite — RA 10401969 — 10401969@mackenzista.com.br

3. Glossário

Lista de termos específicos do contexto deste estudo (e-commerce, ciência de dados e comunicação de resultados), para facilitar a compreensão do documento por um leitor não familiarizado com a área.

Tabela 1 — Glossário

Termo	Definição
Marketplace	Plataforma digital que reúne diversos vendedores (lojistas) em um único canal de vendas, intermediando a venda entre o lojista e o consumidor final.
Dataset	Conjunto de dados estruturado, geralmente organizado em tabelas, usado como base para uma análise.
Metadados	Dados que descrevem outros dados — por exemplo, o significado, o tipo e a origem de cada coluna de uma tabela.
Outlier	Valor atípico, muito distante dos demais valores de uma variável, que pode indicar uma situação excepcional ou um erro de coleta.
Assimetria	Medida que indica se a distribuição de uma variável se estende mais para a direita (valor positivo, poucos valores muito altos) ou para a esquerda (valor negativo).
Review score	Nota de avaliação dada pelo cliente a um pedido, em uma escala de 1 (muito insatisfeito) a 5 (muito satisfeito).
Nota baixa	Neste estudo, avaliação com nota 1 ou 2, usada como indicador de cliente insatisfeito.
Frete (freight)	Valor cobrado pelo transporte do produto até o cliente.
Taxa de atraso	Percentual de pedidos entregues depois da data estimada informada ao cliente.
Correlação	Medida estatística que indica o grau de relação entre duas variáveis numéricas, variando de -1 (relação inversa perfeita) a +1 (relação direta perfeita).
Data storytelling	Abordagem estruturada para comunicar insights de dados, combinando três

Termo	Definição
	elementos: dados, narrativa e visualização.
Setup, conflito, ponto de virada e resolução	Os quatro momentos da estrutura narrativa adotada na disciplina para organizar uma apresentação de resultados (ver Seção 12).

4. Lista de Abreviaturas e Siglas

Tabela 2 — Abreviaturas e siglas

Sigla	Significado
AED	Análise Exploratória de Dados
AVA	Ambiente Virtual de Aprendizagem
CD	Ciência de Dados
CSV	Comma-Separated Values (formato de arquivo de dados separados por vírgula)
DP	Desvio padrão
IQR	Interquartile Range (intervalo interquartil, usado para identificar outliers)
LGPD	Lei Geral de Proteção de Dados (Lei nº 13.709/2018)
NA	Not Available (valor ausente)
ODS	Objetivos de Desenvolvimento Sustentável (ONU)
RA	Registro Acadêmico
UF	Unidade da Federação (estado)

5. Objetivo de Estudo

Investigar, por meio de análise exploratória de dados reais da Olist, em que medida o atraso e a duração da entrega dos pedidos se relacionam com a satisfação do cliente, medida pela nota de avaliação, de modo a propor uma solução analítica que apoie a redução desse impacto.

6. Contexto do Estudo

6.1 A organização: Olist

A Olist é descrita, na página oficial do dataset no Kaggle, como uma das maiores plataformas de marketplace do Brasil. A empresa conecta pequenos e médios lojistas de todo o país a diversos canais de venda por meio de um contrato único, cuidando também da logística de entrega em parceria com transportadoras. Dessa forma, pequenos vendedores conseguem distribuir seus produtos em múltiplos marketplaces sem precisar negociar individualmente com cada um deles.

Dados complementares sobre a empresa, levantados em reportagens especializadas (TechCrunch) e na base de dados CBInsights, referentes principalmente ao período de 2021 (ano da rodada de investimento Série E):

Tabela 3 — Dados complementares sobre a Olist

Aspecto	Informação
Fundação e sede	Fundada em 2015 (originalmente com o nome Solidarium), com sede em Curitiba (PR).
Fundador/CEO	Tiago Dalvi.
Porte (colaboradores)	Cerca de 500 colaboradores em dezembro de 2020, crescendo para aproximadamente 1.400 em dezembro de 2021 (a empresa relata ter triplicado de tamanho em 2021).

Aspecto	Informação
Base de clientes (lojistas)	Mais de 45.000 lojistas/varejistas clientes, segundo declaração do próprio CEO à imprensa em dezembro de 2021.
Escopo de atuação	Além do marketplace (Olist Store), a empresa passou a oferecer sistema de ERP, conta digital para gestão financeira, sistema de PDV (ponto de venda) integrado e ferramentas para criação de vitrines virtuais (Olist Shops).
Expansões recentes (2021)	Quatro aquisições no ano: Clickspace (social commerce), PAX Logística (mais de 4.000 motoristas cadastrados), VNDA e Tiny ERP (ferramentas de comércio para pequenos negócios).
Captação de investimento	Mais de US$ 318 milhões captados desde a fundação, atingindo valuation de US$ 1,5 bilhão na rodada Série E (dezembro de 2021), liderada pela Wellington Management, com participação de Goldman Sachs Asset Management e SoftBank, entre outros.
Concorrentes	Segundo a base CBInsights, concorrentes diretos incluem Nuvemshop, VTEX, Elo7, Linx e Cnova.

Observação: estes dados têm como referência principalmente o ano de 2021 (mais recentes disponíveis nas fontes consultadas) e podem não refletir o porte ou o escopo atual da empresa. Uma declaração oficial de missão, visão e valores, nas palavras da própria Olist, não foi localizada nas fontes consultadas até o momento.

6.2 Problema de pesquisa

O problema de pesquisa deste estudo é investigar em que medida atrasos na entrega dos pedidos — comparando a data estimada de entrega (order_estimated_delivery_date) com a data real de entrega ao cliente (order_delivered_customer_date) — impactam a satisfação do cliente, medida pela nota de avaliação (review_score, de 1 a 5).

6.3 Associação com os Objetivos de Desenvolvimento Sustentável (ODS)

O problema de pesquisa escolhido relaciona-se principalmente ao **ODS 9 — Indústria, Inovação e Infraestrutura**, tema diretamente ligado à eficiência da infraestrutura logística e de distribuição de produtos, um dos pilares da operação da Olist como conectora de vendedores a canais de venda. Secundariamente, o tema também toca o **ODS 12 — Consumo e Produção Responsáveis**, na medida em que atrasos e falhas de entrega representam ineficiências na cadeia de distribuição de produtos. A análise por estado realizada nesta etapa (Seção 11.9) reforça a ligação com o ODS 9, ao mostrar que o desempenho de entrega é desigual entre as regiões do país.

7. Referências de Aquisição do Dataset

O dataset utilizado neste projeto é o “Brazilian E-Commerce Public Dataset by Olist”, disponibilizado publicamente na plataforma Kaggle pelo usuário oficial da empresa (olistbr).

- **Fonte:** https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce
- **Período da coleta:** os dados abrangem aproximadamente 100 mil pedidos realizados na plataforma entre setembro de 2016 e outubro de 2018 (datas mínima e máxima de compra verificadas na Tabela 17).
- **Limitações de uso:** o dataset é de uso público para fins de estudo e pesquisa (conforme licença disponibilizada no Kaggle). Os dados foram anonimizados pela Olist — por exemplo, na tabela de avaliações, nomes de empresas parceiras mencionados em comentários de texto foram substituídos por nomes de casas fictícias da série Game of Thrones, preservando a confidencialidade comercial dos parceiros.

8. Descrição da Origem dos Dados

Os dados foram gerados a partir da operação real da Olist como marketplace: cada pedido realizado por um cliente em um dos canais de venda parceiros gera registros relacionados a cliente, produto,

vendedor, pagamento, frete/entrega e, quando aplicável, avaliação do pedido pelo cliente. Por se tratar de dados operacionais de uma empresa em funcionamento, eles refletem o comportamento real de compra no comércio eletrônico brasileiro entre 2016 e 2018.

9. Descrição do Dataset (Metadados)

O dataset é composto por 9 arquivos no formato CSV, armazenados no repositório do projeto na pasta dados/. Os metadados a seguir foram levantados a partir da leitura direta dos arquivos (contagem real de linhas, colunas e valores), e não de estimativas. As tabelas se relacionam principalmente pela chave **order_id** (pedido), que liga pedidos, itens, pagamentos e avaliações; clientes, produtos e vendedores são ligados por customer_id, product_id e seller_id.

9.1 olist_customers_dataset.csv — 99.441 linhas

Tabela 4 — Atributos de olist_customers_dataset.csv

Coluna	Descrição
customer_id	Identificador único de cliente por pedido (muda a cada novo pedido do mesmo cliente).
customer_unique_id	Identificador estável do cliente, que se repete caso a mesma pessoa faça mais de um pedido.
customer_zip_code_prefix	Prefixo do CEP do endereço do cliente.
customer_city	Cidade do cliente (4.119 cidades distintas no dataset).
customer_state	Sigla do estado do cliente (27 UFs representadas, cobrindo todo o Brasil).

Observação: Não há valores nulos em nenhuma coluna desta tabela.

9.2 olist_geolocation_dataset.csv — 1.000.163 linhas

Tabela 5 — Atributos de olist_geolocation_dataset.csv

Coluna	Descrição
geolocation_zip_code_prefix	Prefixo do CEP (19.015 prefixos distintos).
geolocation_lat	Latitude aproximada do CEP.
geolocation_lng	Longitude aproximada do CEP.
geolocation_city	Nome da cidade correspondente ao CEP.
geolocation_state	Sigla do estado correspondente ao CEP.

Observação: É a maior tabela do dataset (61,3 MB). Não há valores nulos.

9.3 olist_order_items_dataset.csv — 112.650 linhas

Tabela 6 — Atributos de olist_order_items_dataset.csv

Coluna	Descrição
order_id	Identificador do pedido ao qual o item pertence.
order_item_id	Número sequencial do item dentro do pedido.
product_id	Identificador do produto vendido.
seller_id	Identificador do vendedor responsável pelo item.
shipping_limit_date	Data-limite para o vendedor entregar o item à transportadora.
price	Preço do item (em reais).
freight_value	Valor do frete referente ao item.

Observação: Não há valores nulos.

9.4 olist_order_payments_dataset.csv — 103.886 linhas

Tabela 7 — Atributos de olist_order_payments_dataset.csv

Coluna	Descrição
order_id	Identificador do pedido.
payment_sequential	Número sequencial do pagamento.
payment_type	Tipo de pagamento. Valores observados: boleto, credit_card, debit_card, voucher, not_defined.
payment_installments	Número de parcelas (de 0 a 24 no dataset).
payment_value	Valor pago (em reais).

Observação: Não há valores nulos.

9.5 olist_order_reviews_dataset.csv — 99.224 linhas

Tabela 8 — Atributos de olist_order_reviews_dataset.csv

Coluna	Descrição
review_id	Identificador da avaliação.
order_id	Identificador do pedido avaliado.
review_score	Nota da avaliação, de 1 a 5.
review_comment_title	Título do comentário (87.656 valores nulos).
review_comment_message	Mensagem do comentário (58.247 valores nulos).
review_creation_date	Data em que a avaliação foi enviada.
review_answer_timestamp	Data/hora em que a avaliação foi respondida na plataforma.

9.6 olist_orders_dataset.csv — 99.441 linhas

Tabela 9 — Atributos de olist_orders_dataset.csv

Coluna	Descrição
order_id	Identificador único do pedido.
customer_id	Identificador do cliente (por pedido).
order_status	Situação do pedido (delivered, shipped, canceled, unavailable, invoiced, processing, created, approved).
order_purchase_timestamp	Data/hora da compra.
order_approved_at	Data/hora da aprovação do pagamento (160 valores nulos).
order_delivered_carrier_date	Data de entrega à transportadora (1.783 valores nulos).
order_delivered_customer_date	Data de entrega ao cliente (2.965 valores nulos).
order_estimated_delivery_date	Data estimada de entrega informada ao cliente.

9.7 olist_products_dataset.csv — 32.951 linhas

Tabela 10 — Atributos de olist_products_dataset.csv

Coluna	Descrição
product_id	Identificador único do produto.
product_category_name	Categoria do produto, em português (610 valores nulos; 73 categorias distintas).
product_name_lenght	Quantidade de caracteres do nome do produto (610 valores nulos).
product_description_lenght	Quantidade de caracteres da descrição (610 valores nulos).
product_photos_qty	Quantidade de fotos do anúncio (610 valores nulos).
product_weight_g	Peso em gramas (2 valores nulos).
product_length_cm, height_cm,	Dimensões do produto em centímetros (2 valores nulos cada).

Coluna	Descrição
width_cm	

9.8 olist_sellers_dataset.csv — 3.095 linhas

Tabela 11 — Atributos de olist_sellers_dataset.csv

Coluna	Descrição
seller_id	Identificador único do vendedor.
seller_zip_code_prefix	Prefixo do CEP do vendedor.
seller_city	Cidade do vendedor.
seller_state	Sigla do estado do vendedor (23 estados representados).

9.9 product_category_name_translation.csv — 71 linhas

Tabela 12 — Atributos de product_category_name_translation.csv

Coluna	Descrição
product_category_name	Nome da categoria em português.
product_category_name_english	Tradução da categoria para o inglês.

9.10 Metadados padronizados do dataset (visão geral)

Conforme o padrão apresentado na Aula 2 da disciplina, seguem os metadados gerais do dataset como um todo.

Tabela 13 — Metadados padronizados do dataset

Item	Descrição
Tipo de arquivo	CSV (Comma-Separated Values), 9 arquivos.
Origem dos dados	Aberta (dataset público no Kaggle, publicado pela própria Olist).
Sensibilidade	Dados anonimizados pela Olist. Não há nomes de pessoas físicas; há localização aproximada (cidade/estado e CEP agregado por prefixo) de clientes e vendedores, o que exige cuidado ao divulgar granularidades mais finas.
Validade	Dados coletados entre 2016 e 2018. Refletem o comportamento do e-commerce brasileiro nesse período; podem não representar o cenário atual (prazos de entrega, meios de pagamento e comportamento do consumidor evoluem ao longo do tempo).
Proprietário do dado	Olist (empresa), que disponibilizou o dataset publicamente na plataforma Kaggle.
Informações adicionais	O dataset é amplamente utilizado em projetos educacionais de ciência de dados, com mais de 800 notebooks públicos de outros autores disponíveis na própria página do Kaggle.
Restrições de uso (LGPD)	Por se tratar de dados já anonimizados e disponibilizados publicamente pela própria empresa responsável, para fins educacionais, não foram identificadas restrições adicionais de uso à luz da LGPD. Ainda assim, nenhuma tentativa de reidentificação de clientes ou vendedores deve ser realizada.
Descrição dos atributos	Detalhada por arquivo nas Seções 9.1 a 9.9 e, do ponto de vista estatístico, na Seção 11.2.

10. Proposta de Solução Analítica

Com base na análise exploratória detalhada na Seção 11, propõe-se o desenvolvimento de um **painel analítico de monitoramento do risco de atraso**, que relacione o desempenho de entrega (atraso e tempo total) com a satisfação do cliente, por estado (UF) do cliente e por categoria de produto. O objetivo prático dessa proposta é apoiar a Olist na identificação de rotas, regiões ou categorias com maior risco de atraso, de modo a priorizar ações corretivas junto a vendedores e transportadoras parceiras.

O gap identificado é que a Olist aparentemente já estima prazos de entrega com folga — em média, a entrega real acontece quase 12 dias antes do prazo estimado —, mas não há evidência, nos dados disponíveis, de um mecanismo que trate de forma diferenciada os pedidos com alto risco de atraso. A AED desta etapa mostra que esse grupo é pequeno (6,65% das avaliações de pedidos entregues), mas concentra a insatisfação: 62,4% dessas avaliações têm nota 1 ou 2. Mostra também que a taxa de atraso varia de 3,96% (PR) a 17,04% (MA) entre os estados com pelo menos 500 pedidos, o que indica onde o painel poderia concentrar a atenção.

10.1 Pipeline de dados para apoiar o processo analítico

O termo “pipeline de dados” não foi detalhado nos materiais de apoio da disciplina disponibilizados até o momento; a descrição abaixo segue o conceito geral da área de Ciência de Dados, descrevendo as etapas efetivamente realizadas (ou planejadas) neste projeto.

Tabela 14 — Pipeline de dados do projeto

Etapa	Descrição
1. Extração	Download dos 9 arquivos CSV públicos do Kaggle (olistbr/brazilian-ecommerce) e armazenamento no repositório GitHub do projeto (pasta dados/).
2. Carga	Leitura dos arquivos CSV com a biblioteca pandas, em um notebook Jupyter (Python).
3. Tratamento/Limpeza	Conversão de colunas de data (texto) para o tipo datetime; cálculo de variáveis derivadas (atraso_entrega_dias, tempo_entrega_dias, situação de entrega e faixa de atraso); identificação e contagem de valores nulos.
4. Análise exploratória	Perfil estatístico de todas as colunas, medidas de posição e dispersão, distribuição e frequência, outliers (método IQR), correlações, comparação entre pedidos no prazo e atrasados e análise por estado (Seção 11).
5. Visualização	Gráficos (histogramas, boxplot, barras e matriz de correlação) com matplotlib e seaborn, em paleta sóbria de tons de cinza com destaque em vermelho para o atraso.
6. Comunicação	Estruturação dos achados em data storytelling (Seção 12) e, na etapa final, gravação do vídeo de apresentação.

11. Análise Exploratória de Dados

Esta seção descreve os resultados obtidos no notebook Jupyter “01_analise_exploratoria_olist.ipynb” (pasta notebooks/ do repositório), complementando os metadados da Seção 9. Todos os números foram extraídos da execução do notebook sobre os arquivos originais do dataset. Em relação à Etapa 2, o notebook foi revisado (correção do caminho de leitura dos dados, para que ele execute a partir da pasta notebooks/) e ampliado com o perfil estatístico de todas as colunas, novos gráficos de distribuição, a comparação entre pedidos no prazo e atrasados e a análise por estado.

11.1 Dimensões e tipos de dados

O dataset soma 9 tabelas e 52 colunas. As maiores tabelas são geolocation (1.000.163 linhas), order_items (112.650), order_payments (103.886), orders (99.441) e order_reviews (99.224). Do ponto de vista de tipos, há quatro grupos de colunas: **identificadores** (códigos alfanuméricos como order_id e customer_id, que servem apenas para ligar as tabelas), **numéricas contínuas ou discretas** (preço, frete, valor pago, peso, dimensões, nota), **categóricas** (estado, cidade, categoria, tipo de pagamento, status) e **datas**. As colunas de data são lidas como texto e foram convertidas para o tipo datetime antes da análise. Algumas colunas são numéricas no arquivo, mas representam códigos (prefixos de CEP, número sequencial do item e do pagamento); nelas não faz sentido calcular média ou variância, e por isso foram tratadas como categóricas.

11.2 Perfil estatístico de cada coluna

As Tabelas 15 a 17 apresentam, para cada coluna do dataset, o número de exemplares (valores preenchidos), a quantidade de valores ausentes (NAs) e as medidas adequadas ao seu tipo. Para as numéricas: valor mínimo e máximo, média, mediana, variância, desvio padrão e quantidade de outliers pelo método IQR. Para as categóricas e identificadores: número de valores distintos e o valor mais frequente. Para as datas: o período coberto.

Tabela 15 — Perfil das colunas numéricas (inclui as duas variáveis derivadas)

Tabela.coluna	n	NAs	Mín.	Máx.	Média	Mediana	Variância	DP	Outliers IQR
geolocation.geolocation_lat	1.000.163	0	-36,61	45,07	-21,18	-22,92	32,67	5,72	168.240
geolocation.geolocation_lng	1.000.163	0	-101,47	121,11	-46,39	-46,64	18,23	4,27	42.348
order_items.price	112.650	0	0,85	6.735	120,65	74,99	33.721,42	183,63	8.427
order_items.freight_value	112.650	0	0	409,68	19,99	16,26	249,84	15,81	12.134
order_payments.payment_installments	103.886	0	0	24	2,85	1	7,22	2,69	6.313
order_payments.payment_value	103.886	0	0	13.664,08	154,10	100	47.303,67	217,49	7.981
order_reviews.review_score	99.224	0	1	5	4,09	5	1,82	1,35	14.575
products.product_name_lenght	32.341	610	5	76	48,48	51	104,98	10,25	290
products.product_description_lenght	32.341	610	4	3.992	771,50	595	403.371,35	635,12	2.078
products.product_photos_qty	32.341	610	1	20	2,19	1	3,02	1,74	849
products.product_weight_g	32.949	2	0	40.425	2.276,47	700	18.335.855,69	4.282,04	4.551
products.product_length_cm	32.949	2	7	105	30,82	25	286,10	16,91	1.380
products.product_height_cm	32.949	2	2	105	16,94	13	185,98	13,64	1.892
products.product_width_cm	32.949	2	6	118	23,20	20	145,90	12,08	912
orders.atraso_entrega_dias (derivada)	96.476	2.965	-147	188	-11,88	-12	103,71	10,18	4.301
orders.tempo_entrega_dias (derivada)	96.476	2.965	0	209	12,09	10	91,24	9,55	5.025

n = valores preenchidos; DP = desvio padrão; outliers contados pelo critério Q1 − 1,5×IQR / Q3 + 1,5×IQR.

Tabela 16 — Perfil das colunas categóricas, identificadores e datas em texto

Tabela.coluna	n	NAs (%)	Distintos	Valor mais frequente (frequência)
customers.customer_id	99.441	0 (0,00%)	99.441	identificador único
customers.customer_unique_id	99.441	0 (0,00%)	96.096	identificador (máx. 17 repetições)
customers.customer_zip_code_prefix	99.441	0 (0,00%)	14.994	22790 (142)
customers.customer_city	99.441	0 (0,00%)	4.119	sao paulo (15.540)
customers.customer_state	99.441	0 (0,00%)	27	SP (41.746)
geolocation.geolocation_zip_code_prefix	1.000.163	0 (0,00%)	19.015	24220 (1.146)
geolocation.geolocation_city	1.000.163	0 (0,00%)	8.011	sao paulo (135.800)
geolocation.geolocation_state	1.000.163	0 (0,00%)	27	SP (404.268)
order_items.order_id	112.650	0 (0,00%)	98.666	identificador (máx. 21 repetições)
order_items.order_item_id	112.650	0 (0,00%)	21	1 (98.666)
order_items.product_id	112.650	0 (0,00%)	32.951	identificador (máx. 527 repetições)
order_items.seller_id	112.650	0 (0,00%)	3.095	identificador (máx. 2.033 repetições)
order_items.shipping_limit_date	112.650	0 (0,00%)	93.318	data em texto
order_payments.order_id	103.886	0 (0,00%)	99.440	identificador (máx. 29 repetições)
order_payments.payment_sequential	103.886	0 (0,00%)	29	1 (99.360)
order_payments.payment_type	103.886	0 (0,00%)	5	credit_card (76.795)
order_reviews.review_id	99.224	0 (0,00%)	98.410	identificador (máx. 3 repetições)
order_reviews.order_id	99.224	0 (0,00%)	98.673	identificador (máx. 3 repetições)
order_reviews.review_comment_title	11.568	87.656 (88,34%)	4.527	Recomendo (423)

Tabela.coluna	n	NAs (%)	Distintos	Valor mais frequente (frequência)
order_reviews.review_comment_message	40.977	58.247 (58,70%)	36.159	Muito bom (230)
order_reviews.review_creation_date	99.224	0 (0,00%)	636	data em texto
order_reviews.review_answer_timestamp	99.224	0 (0,00%)	98.248	data em texto
orders.order_id	99.441	0 (0,00%)	99.441	identificador único
orders.customer_id	99.441	0 (0,00%)	99.441	identificador único
orders.order_status	99.441	0 (0,00%)	8	delivered (96.478)
products.product_id	32.951	0 (0,00%)	32.951	identificador único
products.product_category_name	32.341	610 (1,85%)	73	cama_mesa_banho (3.029)
sellers.seller_id	3.095	0 (0,00%)	3.095	identificador único
sellers.seller_zip_code_prefix	3.095	0 (0,00%)	2.246	14940 (49)
sellers.seller_city	3.095	0 (0,00%)	611	sao paulo (694)
sellers.seller_state	3.095	0 (0,00%)	23	SP (1.849)
category_translation.product_category_name	71	0 (0,00%)	71	agro_industria_e_comercio (1)
category_translation.product_category_name_english	71	0 (0,00%)	71	agro_industry_and_commerce (1)

Tabela 17 — Perfil das colunas de data da tabela orders (após conversão para datetime)

Coluna	n	NAs (%)	Data mínima	Data máxima
orders.order_purchase_timestamp	99.441	0 (0,00%)	2016-09-04	2018-10-17
orders.order_approved_at	99.281	160 (0,16%)	2016-09-15	2018-09-03
orders.order_delivered_carrier_date	97.658	1.783 (1,79%)	2016-10-08	2018-09-11
orders.order_delivered_customer_date	96.476	2.965 (2,98%)	2016-10-11	2018-10-17
orders.order_estimated_delivery_date	99.441	0 (0,00%)	2016-09-30	2018-11-12

A leitura dessas tabelas permite destacar alguns pontos:

- **Preço, frete, valor pago e peso** têm média bem acima da mediana (por exemplo, preço médio de R$ 120,65 contra mediana de R$ 74,99) e assimetria positiva: a maioria dos pedidos é de baixo valor, com poucos pedidos muito caros. Isso explica o número elevado de outliers nessas variáveis e justifica usar a mediana como medida de referência.
- Há **valores mínimos iguais a zero** em freight_value (frete grátis), payment_value e product_weight_g. Os dois primeiros podem refletir promoções ou vouchers; peso zero é provavelmente um erro de cadastro, mas não afeta o problema de pesquisa.
- A tabela **geolocation** tem latitudes e longitudes máximas fora do território brasileiro (latitude 45,07; longitude 121,11). O notebook identificou 42 coordenadas fora de um retângulo aproximado do Brasil (0,004% da tabela) — um problema de qualidade pontual, que não interfere nesta análise, pois ela não usa coordenadas.
- O período dos pedidos vai de **04/09/2016 a 17/10/2018**; como as datas estimadas chegam a 12/11/2018, os pedidos mais recentes ainda estavam em trânsito no momento da extração, o que ajuda a explicar parte dos NAs na data de entrega.
- Os clientes estão concentrados em **SP** (41.746 registros, cerca de 42% do total), e a categoria mais frequente entre os produtos é **cama_mesa_banho**.

11.3 Valores ausentes (missing values)

Fora dos comentários de avaliação, o dataset tem poucos valores ausentes. Na tabela orders, 2.965 pedidos (2,98%) não possuem data de entrega ao cliente; desses, a maioria está com status “shipped” (1.107), “canceled” (619) ou “unavailable” (609), ou seja, pedidos que não chegaram a ser entregues — por isso foram excluídos dos cálculos de atraso, e não preenchidos artificialmente. Na tabela order_reviews, 88,34% das avaliações não têm título e 58,70% não têm mensagem: a maior

parte dos clientes avalia apenas com a nota. Em products, 610 produtos (1,85%) não têm categoria nem atributos de descrição, e 2 não têm peso e dimensões.

11.4 Medidas de posição e dispersão das variáveis centrais

Tabela 18 — Medidas de posição e dispersão das variáveis do problema de pesquisa

Medida	atraso_entrega_dias	tempo_entrega_dias	review_score
Exemplares (n)	96.476	96.476	99.224
Média	-11,88	12,09	4,09
Mediana	-12	10	5
Moda	-14	7	5
Mínimo / Máximo	-147 / 188	0 / 209	1 / 5
Q1 / Q3	-17 / -7	6 / 15	4 / 5
Variância	103,71	91,24	1,82
Desvio padrão	10,18	9,55	1,35
Coeficiente de variação	-85,75%	78,98%	32,98%

O atraso médio negativo indica que, em geral, o pedido chega cerca de 12 dias **antes** do prazo informado. O tempo total de entrega tem mediana de 10 dias, e a nota mais comum é a máxima (5). Os coeficientes de variação altos das duas variáveis de entrega mostram grande dispersão: a experiência de entrega é bastante desigual entre os pedidos.

11.5 Distribuição e frequência

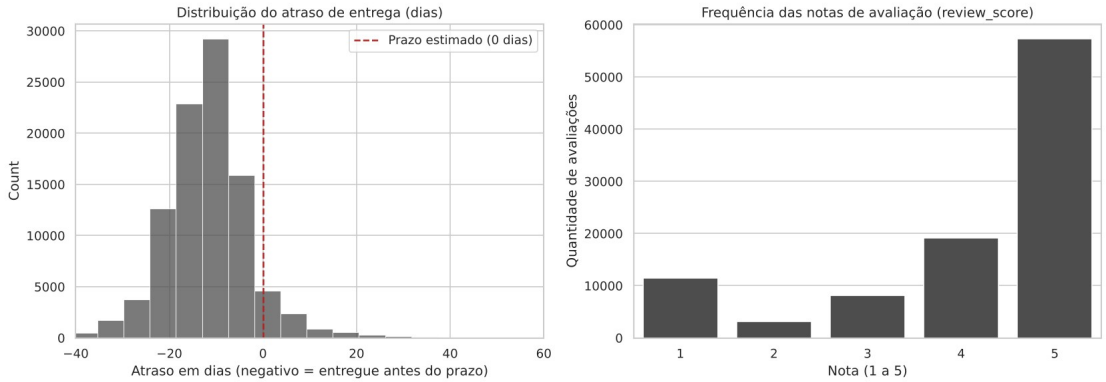


Figura 1 — Distribuição do atraso de entrega e frequência das notas de avaliação

A distribuição do atraso é concentrada à esquerda do zero (entregas antecipadas), com uma cauda à direita formada pelos pedidos atrasados. A distribuição das notas é fortemente concentrada na nota 5 (57.328 avaliações), seguida da nota 4, com uma quantidade menor, mas não desprezível, de notas 1 (11.424 avaliações). Quanto ao status, 97,02% dos pedidos estão como “delivered”. Entre os pagamentos, 73,92% foram feitos com cartão de crédito, 19,04% com boleto, 5,56% com voucher e 1,47% com cartão de débito.

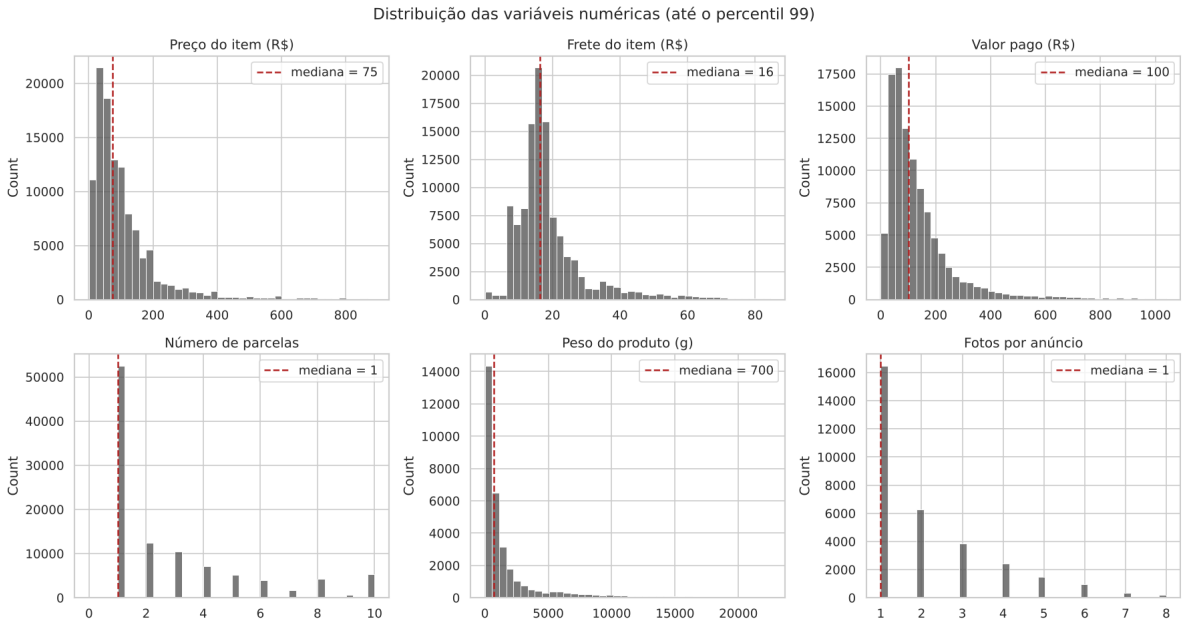


Figura 2 — Distribuição das demais variáveis numéricas (até o percentil 99)

A Figura 2 confirma visualmente a assimetria à direita de preço, frete, valor pago e peso. A maior parte das compras é paga em uma única parcela (mediana = 1) e a maior parte dos anúncios tem apenas uma foto.

11.6 Outliers

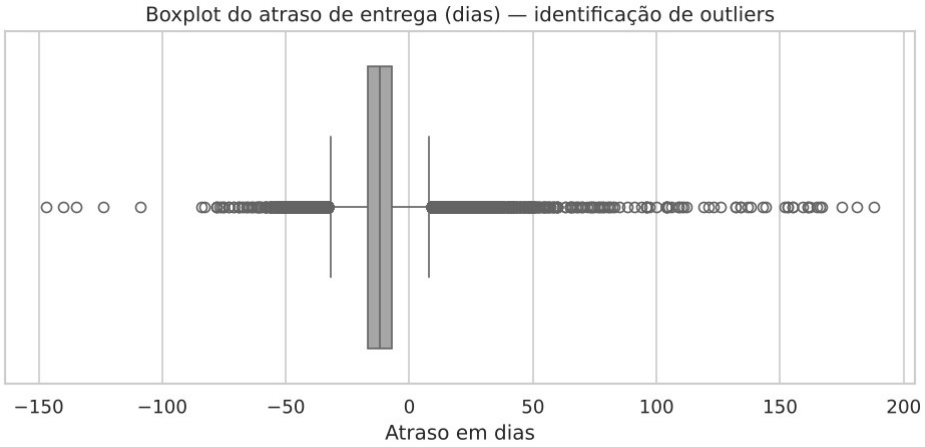


Figura 3 — Boxplot do atraso de entrega (identificação de outliers)

Pelo método IQR, 4.301 pedidos (4,46% dos entregues) foram identificados como outliers de atraso; o limite superior calculado foi de 8 dias de atraso, e o caso mais extremo chegou a 188 dias. Considerando todas as colunas numéricas (Tabela 15), as maiores proporções de outliers estão em review_score (14,69%), product_weight_g (13,81%) e freight_value (10,77%).

No caso de review_score, o resultado exige cuidado: como a nota é uma escala discreta e a maioria das avaliações é 4 ou 5 (Q1 = 4), o método classifica todas as notas 1 e 2 como outliers. Elas não são erros — são justamente os clientes insatisfeitos que interessam ao estudo. Por isso, neste projeto os outliers foram usados como **informação** e não como critério de exclusão de dados.

11.7 Correlações

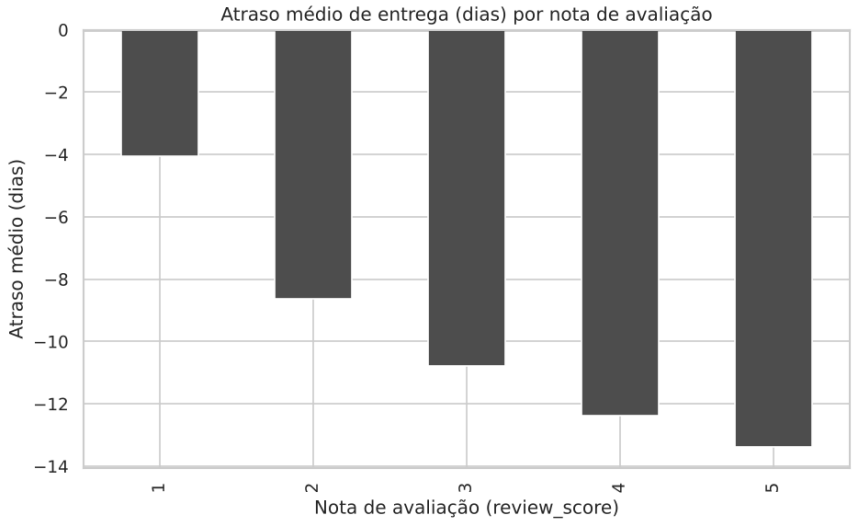


Figura 4 — Atraso médio de entrega (dias) por nota de avaliação

A correlação entre atraso de entrega e nota de avaliação é de -0,267 — negativa, como esperado pela hipótese do problema de pesquisa. Pedidos avaliados com nota 1 tiveram, em média, apenas 4,06 dias de antecipação, enquanto pedidos com nota 5 tiveram 13,39 dias de antecipação.

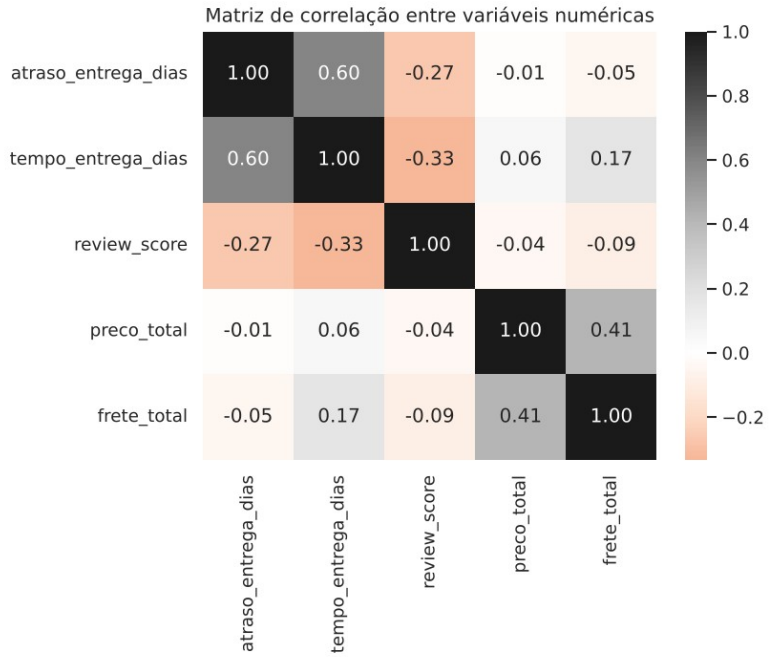


Figura 5 — Matriz de correlação entre variáveis numéricas

A matriz de correlação mostra que o tempo total de entrega tem correlação ainda mais forte com a nota (-0,33) do que o atraso em si (-0,27): a percepção do cliente é influenciada tanto pelo cumprimento do prazo quanto pela duração absoluta da espera. Preço e frete apresentaram correlação fraca com a nota (-0,04 e -0,09), indicando que, neste dataset, o fator logístico pesa mais na satisfação do que o valor pago.

11.8 Pedidos no prazo × pedidos atrasados

Para comunicar o resultado de forma mais direta, os pedidos entregues foram divididos em dois grupos: entregues até a data estimada (“no prazo”) e entregues depois dela (“atrasado”). A unidade

de análise são as avaliações de pedidos entregues (96.359 registros após a junção das tabelas orders e order_reviews).

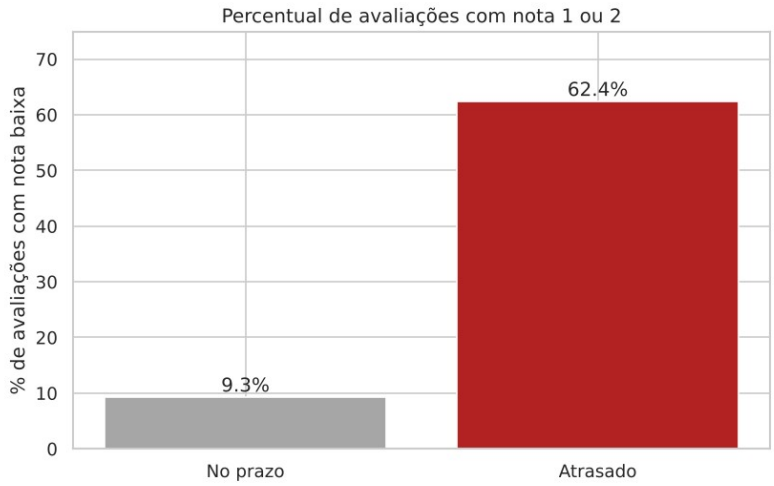


Figura 6 — Percentual de avaliações com nota 1 ou 2: no prazo × atrasado

Tabela 19 — Nota média e notas baixas por faixa de atraso

Situação / faixa de atraso	Avaliações	Nota média	% notas 1 ou 2
No prazo	89.949	4,29	9,28%
Atrasado (total)	6.410	2,27	62,40%
1 a 3 dias	1.856	3,29	32,17%
4 a 7 dias	1.756	2,10	67,65%
8 a 14 dias	1.453	1,68	79,97%
Mais de 14 dias	1.345	1,72	78,29%

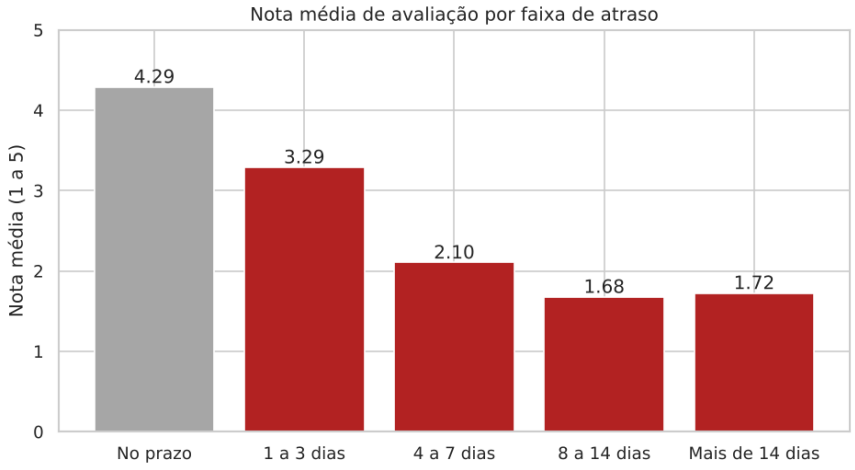


Figura 7 — Nota média de avaliação por faixa de atraso

Este é o achado mais forte do estudo: os pedidos atrasados representam apenas 6,65% das avaliações, mas 62,4% deles recebem nota 1 ou 2, contra 9,3% dos pedidos entregues no prazo. A nota média cai de 4,29 para 3,29 já com 1 a 3 dias de atraso e fica abaixo de 2 a partir de uma semana. A partir de 8 dias de atraso, a nota praticamente estabiliza em um patamar muito baixo — o dano à satisfação já está feito.

11.9 Atraso por estado do cliente

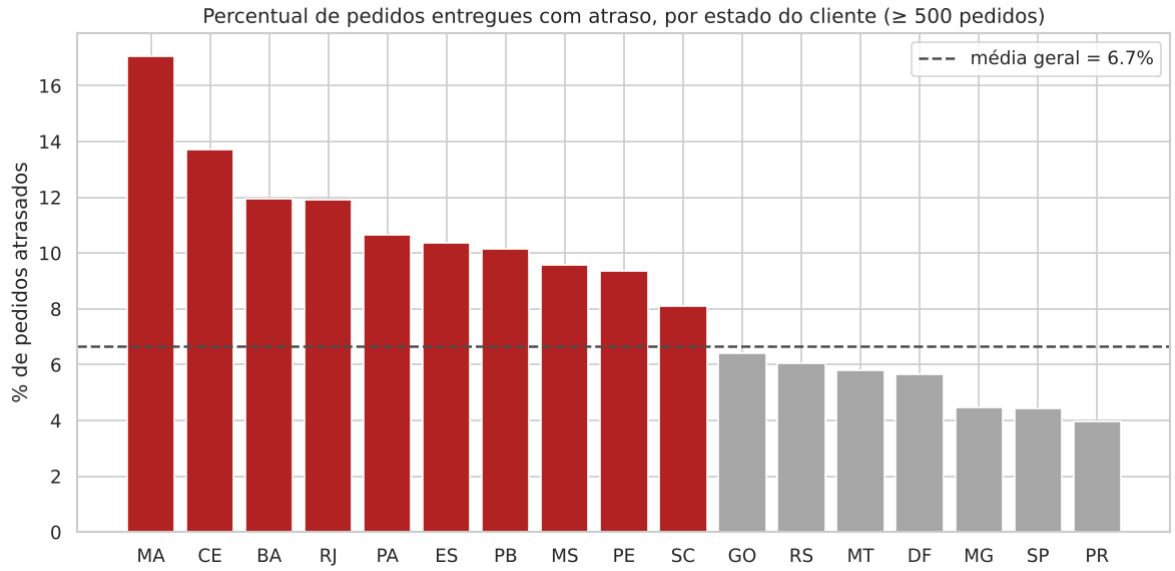


Figura 8 — Percentual de pedidos entregues com atraso, por estado do cliente (≥ 500 pedidos)

Entre os 17 estados com pelo menos 500 pedidos entregues, a taxa de atraso varia de 3,96% (PR) e 4,42% (SP) até 17,04% (MA) e 13,71% (CE); a média geral é de 6,7%. Os estados com mais atraso também têm tempo médio de entrega maior (20,94 dias no MA contra 8,29 dias em SP) e nota média menor (3,84 no MA contra 4,25 em SP). Entre esses estados, a correlação entre taxa de atraso e nota média é de -0,91 — valor que deve ser lido com cautela, por se basear em apenas 17 pontos, mas que é coerente com o restante da análise.

11.10 Síntese dos achados

- A Olist, em geral, entrega antes do prazo: atraso mediano de -12 dias.
- Uma minoria de pedidos (6,65%) chega atrasada, e é nela que se concentra a insatisfação: 62,4% de notas 1 ou 2.
- O tempo total de espera tem correlação com a nota mais forte que o atraso (-0,33 contra -0,27); preço e frete quase não se relacionam com a nota.
- O desempenho de entrega é desigual entre regiões: estados do Norte e do Nordeste e o RJ apresentam as maiores taxas de atraso.
- A qualidade dos dados é boa para o objetivo do estudo: poucos NAs nas colunas centrais, e os problemas encontrados (coordenadas fora do Brasil, peso zero) não afetam as variáveis analisadas.

12. Esboço do Data Storytelling

Esta seção descreve a narrativa que será utilizada na gravação do vídeo final (cinco minutos), seguindo a abordagem de data storytelling apresentada na Aula 3 da disciplina, que combina **dados, narrativa e visualização**, e a estrutura narrativa em quatro momentos: **setup, conflito, ponto de virada e resolução**.

12.1 Elementos da narrativa

Tabela 20 — Elementos do esboço do storytelling

Elemento	Conteúdo
Apresentação do grupo	Projeto desenvolvido individualmente por Felipe Passador Leite (RA 10401969), aluno de Tecnologia em Banco de Dados da Universidade Presbiteriana Mackenzie.
Nome do projeto	Olist: o Peso da Espera.
Empresa / organização de estudo	Olist, marketplace brasileiro que conecta pequenos e médios lojistas a grandes canais de venda e cuida da logística de entrega com transportadoras parceiras.
Área do problema	Logística de última milha no e-commerce e experiência do cliente (satisfação pós-compra).
Descrição do problema / gap	A Olist estima prazos com folga e entrega, em média, 12 dias antes do prometido. Ainda assim, 6,65% das avaliações de pedidos entregues são de pedidos atrasados, e esse pequeno grupo concentra a insatisfação. Não há evidência, nos dados disponíveis, de um mecanismo que trate de forma diferenciada os pedidos e regiões com maior risco de atraso.
Proposta analítica	Painel de monitoramento do risco de atraso por estado e categoria de produto, cruzando taxa de atraso, tempo de entrega e nota média, para priorizar ações com vendedores e transportadoras.
Dados disponíveis	Dataset público da Olist no Kaggle: 9 tabelas CSV, cerca de 100 mil pedidos entre 2016 e 2018, ligados pela chave order_id (pedidos, itens, pagamentos, avaliações, clientes, produtos, vendedores e geolocalização).
Análise exploratória	Perfil de todas as colunas; atraso e tempo de entrega calculados a partir das datas; correlação atraso × nota (-0,27) e tempo × nota (-0,33); 62,4% de notas baixas entre atrasados contra 9,3% no prazo; taxa de atraso de 3,96% (PR) a 17,04% (MA).
Resultados pretendidos	Mostrar que reduzir atrasos — sobretudo nas regiões mais afetadas — é a alavanca mais direta para melhorar a satisfação; oferecer à Olist uma ferramenta para agir de forma preventiva; contribuir com o ODS 9 (infraestrutura logística mais eficiente e menos desigual entre regiões).

12.2 Roteiro da apresentação (5 minutos)

O roteiro abaixo organiza a fala e os elementos visuais de cada momento da narrativa. Os slides terão apenas tópicos curtos e um gráfico por vez, para que a explicação seja feita pela fala, e não pela leitura de texto na tela.

Tabela 21 — Roteiro do vídeo de apresentação

Momento	Tempo	O que será dito	Visual no slide
Setup — o protagonista	0:00–0:50	Apresentação do autor e do projeto. Quem é a Olist: um marketplace que conecta milhares de pequenos lojistas a grandes canais de venda e cuida da entrega. Dimensão dos dados: cerca de 100 mil pedidos reais, 2016–2018.	Título do projeto; três números grandes: 99.441 pedidos · 9 tabelas · 2016–2018.
Conflito — o incidente	0:50–1:50	A Olist promete prazos folgados e, em média, entrega 12 dias antes. Mas nem todo pedido chega: 6,65% atrasam, alguns em mais de 100 dias. Pergunta que guia o estudo: quanto esse atraso custa na satisfação do cliente?	Figura 1 (histograma do atraso), com a cauda à direita do zero destacada em vermelho.
Ponto de virada — os dados respondem	1:50–3:50	Os dados mostram o tamanho do problema: 62,4% dos pedidos atrasados recebem nota 1 ou 2, contra 9,3% dos pedidos no prazo. A nota cai a cada faixa de atraso e fica abaixo de 2 depois de uma semana. Preço e frete quase não importam; o que pesa é a espera. E o atraso não é igual no país: 17% no Maranhão contra 4% em São Paulo e no Paraná.	Sequência de três gráficos: Figura 6 (no prazo × atrasado), Figura 7 (nota por faixa de atraso) e Figura 8 (atraso por estado).
Resolução — a proposta	3:50–5:00	Proposta: um painel de risco de atraso por estado e categoria, que permita à Olist agir antes do atraso acontecer, priorizando as regiões mais afetadas. Impacto esperado: menos clientes insatisfeitos e uma logística mais eficiente e menos desigual (ODS 9). Fechamento: “na Olist, o que pesa na avaliação não é o preço — é a espera”.	Esboço do painel (indicadores por UF) e frase final; link do repositório no GitHub.

13. Cronograma de Atividades

O cronograma foi atualizado em relação à Etapa 2, refletindo a conclusão da Etapa 3 e a previsão para a Etapa 4.

Tabela 22 — Cronograma de atividades

Etapa	Período	Atividades principais
Etapa 1	Concluída (até 14/09/2026)	Escolha da organização (Olist); criação do repositório GitHub; obtenção do dataset; metadados iniciais; definição do problema de pesquisa e dos ODS.
Etapa 2	Concluída (até 02/10/2026)	Análise exploratória em Python/Jupyter Notebook; glossário e lista de abreviaturas; metadados padronizados; proposta de solução analítica e pipeline de dados.
Etapa 3	Concluída (novembro de 2026)	Revisão e ampliação do notebook de AED (perfil de todas as colunas, comparação no prazo × atrasado, análise por estado); ampliação da Seção 11; esboço do data storytelling.
Etapa 4	Previsão: dezembro de 2026	Produção dos slides, gravação do vídeo de cinco minutos, ajustes finais no documento e entrega final do projeto.

14. Repositório do Projeto

Todos os artefatos do projeto estão disponíveis publicamente em **https://github.com/fpassr/Projeto-Aplicado-I**, organizados da seguinte forma:

- **dados/** — os 9 arquivos CSV do dataset da Olist;
- **notebooks/** — notebook “01_analise_exploratoria_olist.ipynb”, figuras geradas e arquivos de perfil estatístico (perfil_colunas.csv e perfil_datas_orders.csv);
- **entregas/** — PDFs entregues em cada etapa do projeto.

15. Referências

DYKES, Brent. Data storytelling: the essential data science skill everyone needs. *Forbes*, 31 mar. 2016. Disponível em: https://www.forbes.com/sites/brentdykes/2016/03/31/data-storytelling-the-essential-data-science-skill-everyone-needs/. Referência indicada no material da Aula 3 da disciplina.

LOPES, Fabio Silva. *Projeto Aplicado I — Aula 3: Storytelling*. São Paulo: Universidade Presbiteriana Mackenzie, 2026. Material de aula.

OLIST. *Brazilian E-Commerce Public Dataset by Olist*. Kaggle. Disponível em: https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce.